

Rangkuman Perkuliahan: Eksplorasi Neural Network dari Linear Regression hingga Hidden Layers

Muhammad Labib¹, Muhammad Shadaam Haidar Yuwono²

^{1,2} Program Studi Teknik Informatika, STMIK Tazkia Bogor
E-mail : 241552010005.shadaam@student.stmik.tazkia.ac.id

Abstrak

Tulisan ini merangkum pengantar neural networks dalam machine learning yang berangkat dari konsep linear regression. Linear regression dipandang sebagai neuron tunggal dengan bobot (weight) dan bias, yang kemudian diperluas menjadi jaringan saraf dengan hidden layer. Pembahasan meliputi arsitektur neural networks, mekanisme forward propagation, evaluasi error menggunakan Mean Squared Error (MSE), serta pengantar backpropagation untuk optimasi bobot. Implementasi sederhana menggunakan Python menunjukkan penurunan MSE dari sekitar 0.9 menjadi 0.01 dalam 1000 epok pada dataset simulasi. Hasil ini menegaskan pentingnya optimasi bobot dan eksperimen arsitektur dalam neural networks.

Kata kunci : Machine Learning, Linear Regression, Neural Networks, Forward Propagation, Backpropagation, MSE.

1. Pendahuluan

Machine learning berkembang dari model statistik sederhana seperti linear regression menuju model non-linear seperti neural networks. Linear regression, yang dinyatakan sebagai $y = mx + c$, dapat dianalogikan sebagai neuron tunggal dengan bobot dan bias. Konsep ini menjadi dasar untuk membangun jaringan saraf dengan banyak neuron dan layer. Neural networks terinspirasi dari neuron biologis, dengan weight berperan sebagai sinapsis. Kompleksitas model meningkat seiring bertambahnya jumlah neuron dan layer, sehingga pemilihan arsitektur umumnya bersifat empiris dan memerlukan dukungan komputasi seperti GPU untuk skala besar.

2. Metode

2.1 Linear Regression sebagai Neuron

Secara umum, fungsi neuron dapat dituliskan sebagai:

$$f(x) = \sum_{i=1}^n w_i x_i + b$$

Model univariate memiliki satu input, sedangkan model multivariate memiliki banyak input, misalnya pada prediksi harga rumah berdasarkan beberapa fitur.

2.2 Arsitektur Neural Networks

Neural networks terdiri dari input layer, satu atau lebih hidden layer, dan output layer. Contoh arsitektur sederhana menggunakan 4 input (termasuk bias), 3 neuron pada hidden layer, dan 1 neuron output, dengan total 15 bobot. Penentuan jumlah layer dan neuron dilakukan melalui eksperimen karena tidak tersedia rumus baku.

2.3 Forward Propagation

Forward propagation menghitung output jaringan berdasarkan bobot awal yang diinisialisasi secara acak. Setiap neuron melakukan operasi penjumlahan berbobot terhadap input. Error dievaluasi menggunakan Mean Squared Error (MSE):

$$MSE = \frac{1}{n} \sum (y - \hat{y})^2$$

Satu epok didefinisikan sebagai satu kali pemrosesan seluruh data pelatihan.

2.4 Backpropagation

Backpropagation digunakan untuk memperbarui bobot dengan menghitung gradien error terhadap bobot. Bobot diperbarui menggunakan metode gradient descent dengan parameter learning rate dan momentum. Proses ini diulang hingga nilai error mencapai batas minimum yang diinginkan.

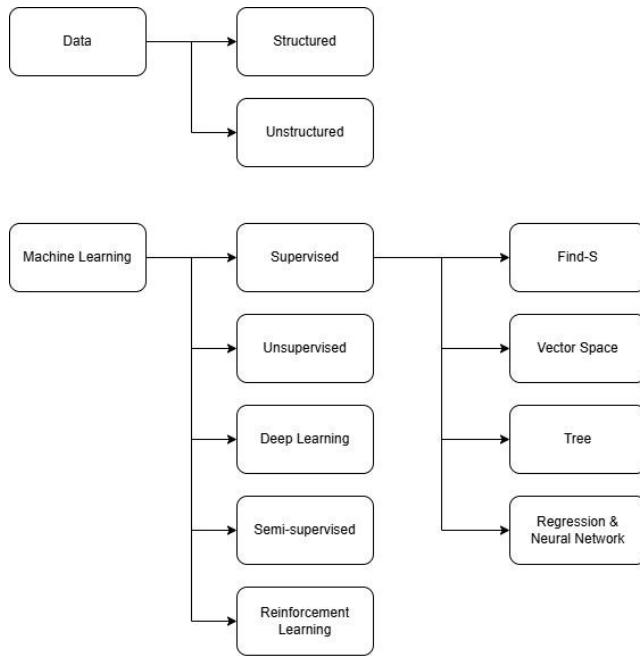
3. Hasil dan Analisis

Eksperimen dilakukan pada dataset simulasi fraud detection berjumlah 20 data yang telah dinormalisasi. Nilai MSE awal sekitar 0.9 dan menurun hingga mendekati 0.01 dalam 1000 epok. Penambahan momentum mempercepat proses konvergensi. Hasil ini menunjukkan bahwa backpropagation efektif dalam mengoptimasi bobot, meskipun kompleksitas komputasi meningkat seiring ukuran model.

4. Kesimpulan

Neural networks merupakan pengembangan dari linear regression yang mampu memodelkan hubungan non-linear. Melalui mekanisme forward propagation dan backpropagation, bobot jaringan dapat dioptimasi untuk meminimalkan error. Eksperimen sederhana menunjukkan penurunan error yang signifikan, menegaskan pentingnya optimasi bobot, pemilihan arsitektur, dan dukungan komputasi dalam penerapan neural networks.

5. Mindmap



Daftar Pustaka

- [1] T. M. Mitchell, *Machine Learning*. McGraw-Hill, 1997.
- [2] A. Ng, *Machine Learning*. Coursera, Stanford University.
- [3] F. Chollet, *Deep Learning with Python*. Manning Publications, 2018.